



Slurm

Installation & Configuration

Lise Jolicoeur - lise.jolicoeur@cea.fr


Plan

- Rappels
- Configuration et activation des composants
- Configuration avancée
- Sécurité dans Slurm


The background of the slide is composed of several large, overlapping triangles in various colors: red, orange, yellow, teal, blue, and purple. These triangles are arranged in a way that they point towards the center, creating a dynamic and modern aesthetic. The word "Rappels" is centered in the white space between these triangles.

Rappels

Slurm - Rappels




Slurm - Rappels



Slurm - Rappels

- **slurmstepd**



Slurm - Rappels

Vocabulaire	Signification
Nodes, partition, Job, Jobstep	Ressources et travaux
Users, Account, Qos, Fairshare, Associations	Restrictions
Backfilling	Ordonnanceur

Commandes :	Utilisez le man ! énormément d'options
sinfo	« Show resources »
squeue	« Show jobs »
sacct	« Show stats of jobs »
scontrol	« Admin show/modify config (slurmctld) »
sacctmgr	« Admin show/modify config (slurmdbd) »
srun, salloc	« Interactive launch »
sbatch	« Batch launch »
scancel	« Cancel job »

The background of the slide is composed of several large, overlapping triangles in various colors: red, orange, yellow, teal, blue, and purple. These triangles are arranged in a way that they point towards the center, creating a dynamic and modern aesthetic. The text is centered within the white space created by these geometric shapes.

Configuration et activation des composants

Slurm - Configuration

- **Fichiers de configuration**

- Fichiers principaux

- /etc/slurm/slurm.conf

- Utilisé par slurmctld
 - Utilisé par slurmd
 - Utilisé par les commandes lignes
 - srun, sbatch, squeue, sinfo...

- /etc/slurm/slurmdbd.conf

- Utilisé par slurmdbd uniquement

Slurm - Configuration

- **Fichiers de configuration**

- Spécificités du format

- # commentaires
 - key=value
 - key=val1,val2,...
 - key=val attr1=a1 attr2=a2 ...
 - key=nodeset[1-10,12-20] attr=ns[1-10,12-20] ...
 - Include other_file_path

ex :

ClusterName=mycluster

NodeName=mynode[1400-1435] ...

Slurm - Activation

- **Services principaux (RedHat style)**
 - Systemd : gestionnaire de système et de services
 - PID 1
 - Services, aussi appelé 'démons'
 - Processus tournant en arrière plan, gérés par le système

Slurm - Activation

- **Services principaux (RedHat style)**
 - slurmdbd
 - `systemctl start/status/stop slurmdbd`
 - slurmctld
 - `systemctl start/status/stop slurmctld`
 - slurmd
 - `systemctl start/status/stop slurmd`
 - `systemctl enable/disable`

Slurm - Activation

- **Services principaux (RedHat style)**
 - Systemctl status

```
● slurmctld.service - Slurm controller daemon
   Loaded: loaded (/usr/lib/systemd/system/slurmctld.service; enabled; vendor preset: disabled)
   Active: active (running) since dim. 2023-02-05 10:08:54 UTC; 21s ago
     Process: 1654 ExecStart=/usr/sbin/slurmctld $SLURMCTLD_OPTIONS (code=exited, status=0/SUCCESS)
    Main PID: 1656 (slurmctld)
      CGroup: /system.slice/slurmctld.service
              └─1656 /usr/sbin/slurmctld
```

Slurm - Configuration

- **Slurmdbd**

- Nécessite la mise en place préalable d'une base de données MySQL
 - Mariadb
- Nécessite la création d'une « database » dédiée à Slurm
 - « slurm_acct_db » par défaut
- Nécessite la fourniture des droits d'accès pour la manipulation depuis slurmdbd
 - Le démon mysql peut être local ou distant

Slurm - Configuration

- **Slurmdbd**

- Peut être utilisé pour gérer différents clusters Slurm
 - Afin d'éviter le déploiement d'une base et d'une instance par cluster
 - Afin de centraliser la définition des accounts / users
 - Afin de centraliser les statistiques et leurs traitements automatisés
 - Outil « sreport » : ex sreport user top

Slurm - Configuration

- **Slurmdbd**

- Est accédé par slurmctld pour
 - l'interrogation des accounts / users / qos / associations / ...
 - l'écriture des états du cluster
 - l'écriture des informations sur les jobs enregistrés et leurs statistiques
 - ...

Slurm - Configuration

- **Slurmdbd**

- Est accédé par les utilisateurs pour
 - Obtenir des informations sur leurs jobs en cours ou passés
- Est accédé par les administrateurs pour
 - Obtenir des informations sur les jobs en cours ou passés
 - Générer des rapports d'utilisation du cluster
 - Modifier les accounts / users / qos / associations / ...

Slurm - Configuration

- **(/etc/slurm/) slurmdbd.conf**
 - Éléments de configuration principaux
 - DbdHost
 - le nom de la machine hébergeant le service slurmdbd
ex : localhost, vm0, ...
 - DbdAddr
 - l'adresse IP (ou un alias) utilisée pour les connexions si différent de ANY
ex : 127.0.0.1, localhost, vm0-eth0, ...
 - DbdPort
 - Le port TCP ouvert en écoute pour slurmdbd, 6819 par défaut

Slurm - Configuration

- **slurmdbd.conf**

- **Éléments de configuration principaux**

- AuthType

- La méthode d'authentification souhaitée
ex : AuthType=auth/munge

- SlurmUser

- Nom de l'utilisateur local qui sera utilisé pour exécuter l'application
ex : slurm, root, ...

- PrivateData

- Permet de limiter la visibilité des informations en fonction des utilisateurs (hors SlurmUser)
si nécessaire
ex : jobs, users, ...

Slurm - Configuration

- **slurmdbd.conf**

- Éléments de configuration principaux

- StorageType / StorageLoc

- Type de DB utilisé (plugin associé)

- ex : StorageType=accounting_storage/mysql

- Nom de la database utilisée sur le backend

- ex : StorageLoc=slurm_acct_db

- StorageHost / StoragePort

- Alias/IP pour l'accès à la DB

- Port TCP pour l'accès à la DB (mysqld en écoute)

- StorageUser / StoragePass (cohérents avec droits définis lors de la création de StorageLoc)

- Utilisateur dans la DB pour accéder à la database Slurm

- Mot de passe pour l'accès à la DB

Slurm - Configuration

- **slurmdbd.conf**

- Éléments de configuration principaux

- LogFile

- Le fichier de log utilisé par le démon (/var/log/slurmdbd.log)

- DebugLevel

- Le niveau de verbosité de la log
 - Utile de l'augmenter pour rechercher l'origine d'un problème

- quiet, fatal, error, info, debug, ...debug5

- DebugFlags

- Utile pour améliorer la verbosité de certaines sous-parties

- ex : DB_JOB, DB_QOS, DB_ASSOC, ...

Slurm - Configuration

- **slurmdbd.conf**
 - Éléments de configuration principaux
 - Encore bien d'autres à découvrir
 - « man slurmdbd.conf »
 - <https://slurm.schedmd.com/slurmdbd.conf.html>

Slurm - Configuration

- **Slurmctld / Slurmd**

- Peuvent partager un même fichier de configuration
 - Doivent même le faire par défaut, sans quoi un avertissement est inscrit dans la log pour le faire savoir pour chaque nœud en infraction (configurable!)
 - Validation par comparaison de hash
- Utilisé aussi par les utilisateurs en ligne de commande
 - Qui doivent connaître les entités du cluster et les modes de communication

Slurm - Configuration

- **Slurmctld / Slurmd**

- Doivent partager la même définition des nœuds intégrés au calculateur
 - Pour permettre des communications arborescentes (scalabilité)
- Disposent de propriétés communes et de leurs propres propriétés
 - Simplifie la factorisation des configurations

Slurm - Configuration

- **(/etc/slurm/) slurm.conf**
 - Éléments de configuration principaux
 - ClusterName
 - Le nom du cluster utilisé.
ex : ensiie, hpc, ...
 - SlurmUser
 - Le nom de l'utilisateur exécutant slurmctld
ex : slurm, root, ... (slurmd s'exécute généralement en tant que root)

Slurm - Configuration

- **slurm.conf**

- Éléments de configuration principaux

- SlurmctldHost (ControlMachine)

- Le 'hostname' de la machine contrôleur.

- Ex : vm0, ...

- SlurmctldHost=slurmctl-primary(12.34.56.78)

- SlurmctldPort

- Le port TCP utilisé par slurmctld (default : 6817)

- SlurmctldTimeout

- Temps d'attente de la réponse du contrôleur avant que le backup prenne le contrôle

- Ex : 300

Slurm - Configuration

- **slurm.conf**

- Éléments de configuration principaux

- StateSaveLocation

- L'emplacement de sauvegarde des fichiers d'état du contrôleur. Utilisés pendant les redémarrage ou les bascules 'high availability'.

- Ex : /var/slurm/slurmctld, /tmp/slurmctld, ...

- SlurmctldDebug

- Niveau de verbosité du contrôleur

- Ex : quiet, fatal, error, info, debug, ...,debug5

- (En live : scontrol setdebug debug4)

- SlurmctldLogFile

- Fichier de log à utiliser (absence → syslog)

- Ex : /var/log/slurmctld.log

Slurm - Configuration

- **slurm.conf**

- Éléments de configuration principaux

- AccountingStorageType

- Le type de « backend » d'accounting

- Ex : accounting_storage/slurmdbd (ou rien...)

- AccountingStorageHost

- La machine à contacter pour le service slurmdbd

- Ex : vm0

- AccountingStorageEnforce

- Le type de contrôle effectué par le contrôleur dans la soumission des jobs à partir des infos de l'« accounting »

- Ex : « associations », « qos »

Slurm - Configuration

- **slurm.conf**

- Éléments de configuration principaux

- SelectType

- Le type d'algorithme de sélection des ressources « consommables » utilisé par le contrôleur.

- Trois principaux choix :

- Sélection de nœuds complets (linear)

- Sélection de cpus individuels dans les nœuds (cons_res, legacy)

- Sélection individuelle dans les nœuds : cpu,gpu,memory,etc (cons_tres)

- Ex : SelectType=select/cons_tres

- SelectTypeParameters

- Paramètres additionnels pour l'algo précédent

- Ex : CR_CORE,CR_CORE_DEFAULT_DIST_BLOCK,CR_ONE_TASK_PER_CORE

Slurm - Configuration

- **slurm.conf**

- Éléments de configuration principaux

- SchedulerType

- Le type d'optimisation de scheduling souhaité.

- Deux choix possibles

- Highest Priority First FIFO (builtin)

- Backfilling (backfill)

- Ex : SchedulerType=sched/backfill


- SchedulerParameters

- Paramètres additionnels pour l'algo précédent

- Ex : bf_window=1440, bf_interval=60,...


Slurm - Configuration

- **slurm.conf**
 - **Éléments de configuration principaux**
 - **SchedulerType backfill**




Slurm - Configuration

- **slurm.conf**
 - **Éléments de configuration principaux**
 - **SchedulerType backfill**




Slurm - Configuration

- **slurm.conf**
 - **Éléments de configuration principaux**
 - **SchedulerType backfill**



Slurm - Configuration

- **slurm.conf**
 - **Éléments de configuration principaux**
 - **SchedulerType backfill**



Slurm - Configuration

- **slurm.conf**

- Éléments de configuration principaux

- PriorityType

- Type d'algorithme de priorisation

- Basic : priorité basée sur l'ordre d'arrivée

- Multifactor : combinaison de différents facteurs (cf cours 1)

- Ex : PriorityType=priority/multifactor

- PriorityWeight{QOS,Fairshare,...}

- Les poids des différents facteurs (cf cours 1)

Slurm - Configuration

- **slurm.conf**
 - Éléments de configuration principaux
 - SlurmdPort
 - Le port TCP utilisé par les démons « slurmd »
Default : 6818
 - SlurmdSpoolDir
 - L'emplacement des fichiers d'état de slurmd
Ex : /var/slurm/slurmd, /tmp/slurmd, ...
 - SlurmdDebug
 - Niveau de verbosité de slurmd
quiet, fatal, error, info, debug, ...debug5
 - SlurmdLogFile
 - Fichier de log utilisé par slurmd (absence → syslog)
Ex : /var/log/slurmd.log

Slurm - Configuration

- **slurm.conf**
 - Éléments de configuration des nœuds
 - 1 ligne par groupement de nœuds identiques
 - **NodeName**
 - Noms des nœuds configurés par cette ligne
 - **Sockets**
 - Nombre de sockets (CPU physique)
 - **CoresPerSocket**
 - Nombre de coeurs par CPU (default : 1)

Slurm - Configuration

- **slurm.conf**

- Éléments de configuration des nœuds

- ThreadsPerCore

- Nombre d'hyperthreads par coeur (default : 1)

- RealMemory

- Quantité de mémoire disponible pour le calcul en Mo

- Exemple :

NodeName=vm[0-3] Socket=1 CoresPerSocket=2 RealMemory=8000


Slurm - Configuration

- **slurm.conf**

- Éléments de configuration des nœuds

- State

- État de base du nœud au démarrage du contrôleur
Ex : UNKNOWN, DOWN, DRAIN, ...



Slurm - Configuration


- **slurm.conf**

- Éléments de configuration des nœuds
 - Exemple complet

```
NodeName=vm[0-3] Sockets=2 CoresPerSocket=32 State=IDLE  
RealMemory=8000
```


Slurm - Configuration

- **slurm.conf**
 - Éléments de configuration des partitions



Slurm - Configuration

- **slurm.conf**

- Éléments de configuration des partitions

- PartitionName

- Nom de la partition

- Ex : vm, haswell, skylake, ...

- Default

- Yes/No, pour indiquer que la partition est la partition par défaut des jobs

- State

- L'état de la partition au premier démarrage de Slurmctld

- Ex : Up, Down, ...

Slurm - Configuration

- **slurm.conf**

- Éléments de configuration des partitions

- Nodes

- Liste des nœuds associés à la partition

- Ex : Nodes=vm[0-3]

- MaxTime

- Durée maximale des jobs dans cette partition en minutes

- Ex : 90, INFINITE, ...

- MaxNodes

- Nombre maximum de nœuds allouables par job dans cette partition

Slurm - Configuration

- **slurm.conf**


- Éléments de configuration des partitions

PartitionName=vm Nodes=vm[0-3] Default=YES MaxTime=INFINITE State=UP

- Propriétés par défaut, peut être influencé par associations/qos

Slurm - Configuration

- **slurm.conf**
 - Éléments de configuration principaux
 - Encore bien d'autres à découvrir
 - « man slurm.conf »
 - <https://slurm.schedmd.com/slurm.conf.html>

The background of the slide is composed of several large, overlapping triangles in various colors: red, orange, yellow, teal, blue, and purple. These triangles are arranged in a way that they point towards the center, creating a dynamic and modern aesthetic. The text is centered within the white space created by these geometric shapes.

Configuration avancée


Slurm - Configuration avancée

- Beaucoup de paramètres sont disponibles....
 - Mais il est préférable de commencer simple et d'optimiser ensuite
 - Les man pages et les docs sont alors indispensables
 - Ainsi qu'un peu de patience et beaucoup de pratique / tests
 - Il existe un générateur de conf
 - Il reste toutefois assez simpliste lui aussi
- <https://slurm.schedmd.com/configurator.html>

Slurm - Configuration avancée

- Optimisations discutées ici
 - Sélection topologique des ressources par le contrôleur
 - Communications arborescentes entre slurmctld et slurmd
 - Confinement et « binding » des processus sur les nœuds pour une meilleure performance


Rappels réseau




Slurm - Configuration avancée

- Sélection topologique des ressources
 - Différentes topologies réseau pour différentes machines


Tore, Hypercube, Fat-Tree, Dragonfly ...




Fat Tree




Torus



Dragonfly




Hypercube



HyperX


Fat tree



Arbre (Fat Tree)

Beaucoup de switchs, mais extensible et bon throughput
=> Summit, Sierra, TGCC...

« Dragonfly »



Slingshot : switchs de 64 ports (high radix), 200Gb/s par port
250 000 nœuds, 3 « switch-to-switch » hops
=> Frontier, El Capitan, LUMI

Slurm - Configuration avancée

- **Sélection topologique des ressources**
 - Plugin « topology » de Slurm
 - Topology/tree permet de définir une hiérarchie de switchs d'interconnexion dans le cas d'un fat tree.
 - Et d'optimiser le remplissage des switchs lors de la sélection des ressources pour chaque job
 - C'est la famille de topologie la plus courante sur les clusters de quelques dizaines/centaines de nœuds
 - TopologyPlugin=topology/tree dans slurm.conf
 - Fichier de conf topology.conf à renseigner

Slurm - Configuration avancée

- **Sélection topologique des ressources**

- Exemple de topology.conf


```
SwitchName=l1 Nodes=vm[0,2]
```

```
SwitchName=l2 Nodes=vm[1,3]
```

```
SwitchName=t0 Switches=l[1-2]
```

Slurm - Configuration avancée

- Communications arborescentes



Slurm - Configuration avancée

- **Communications arborescentes**

- Objectif

- Améliorer la performance des communications entre slurmctld et les slurmd
 - Améliorer l'agrégation des retours d'information des jobs vers le contrôleur

- Moyen

- Hiérarchiser & Paralléliser les communications entre les éléments

Slurm - Configuration avancée

- **Communications arborescentes**


- En arbre avec un « fan-out » défini à l'aide du paramètre `TreeWidth` de `slurm.conf`

Correspond au nombre maximum de destinataires contactés en parallèle par chaque participant

`RoutePlugin=route/default`
`TreeWidth=64`

Slurm - Configuration avancée

- TreeWidth=3



Slurm - Configuration avancée

- **Communications arborescentes**

- Selon la topologie

- En fonction des switchs : envoyé au premier nœud, qui envoie aux autres

- Principe de localité


- RoutePlugin=route/topology

Slurm - Configuration avancée

- **Confinement et binding des processus**
 - Par défaut, l'allocation des ressources est « laxiste »
 - Par défaut, l'allocation est globale pour les processus d'un même nœud
 - Chaque processus accède à l'ensemble des ressources et se déplace d'une unité de calcul (CPU) à une autre au gré de l'OS (préemption)

Slurm - Configuration avancée

- Confinement et binding des processus



Slurm - Configuration avancée

- **Confinement et binding des processus**

- Le fonctionnement par défaut n'est donc pas optimal lorsque :
 - Les processus ont besoin de rester sur les mêmes unités de calcul pendant leur exécution pour bénéficier des effets de cache/accès mémoire
 - Toujours le cas en HPC
 - Le nœud de calcul est partagé entre plusieurs jobs
 - possible avec `select/cons_tres`

Slurm - Configuration avancée

- **Confinement et binding des processus**
 - TaskPlugin permet de mettre en place des mécaniques de confinement et de binding pour résoudre ces problématiques
 - TaskPlugin=task/cgroup est une des méthodes permettant cela
 - A définir dans slurm.conf
 - Fichier de conf cgroup.conf à renseigner

Slurm - Configuration avancée

- **Confinement des processus**

- Les « cgroups »


- Fonctionnalité du noyau Linux
 - Allocation/restrictions de ressources pour des groupes de processus
 - Différentes applications avec différents besoins
 - Contrôle de la consommation
 - Une des technologies utilisée pour la création de 'conteneurs'

Slurm - Configuration avancée

- **Confinement des processus**

- Les « cgroups »

- Fournissent des primitives de regroupement de processus avec inclusion automatique des processus fils
 - Fournissent différents sous-systèmes pour traiter le partage de différentes ressources



Slurm - Configuration avancée

- **Confinement des processus**

- Les « cgroups »

- Concrètement : un chemin dans le système de fichier
 - `mkdir /sys/fs/cgroup/cg1`
 - Ajout d'un processus dans un cgroup :
 - `echo 24982 > /sys/fs/cgroup/cg1/cgroup.procs`
 - Hiérarchique


Slurm - Configuration avancée

- **Confinement des processus**

- Les « cgroups »
 - « Sous-systèmes » considérés :
 - blkio (I/O)
 - cpu (temps)
 - cpuset (coeurs)
 - memory
 - net_prio
 - ...

Slurm - Configuration avancée

- Confinement des processus



Slurm - Configuration avancée

- **Confinement des processus**

```
[root@mordor:~]# mkdir /cgroup
[root@mordor:~]# mkdir /cgroup/cpuset
[root@mordor:~]# mount -t cgroup -o cpuset none /cgroup/cpuset
[root@mordor:~]# ls /cgroup/cpuset/
cpuset.cpus  cpuset.mems  tasks  notify_on_release  release_agent
[root@mordor:~]# mkdir /cgroup/cpuset/students
[root@mordor:~]# mkdir /cgroup/cpuset/profs
[root@mordor:~]# echo 0-2 > /cgroup/cpuset/students/cpuset.cpus
[root@mordor:~]# echo 0 > /cgroup/cpuset/students/cpuset.mems
[root@mordor:~]# echo $PIDS_st > /cgroup/cpuset/students/tasks
[root@mordor:~]# echo 3-7 > /cgroup/cpuset/profs/cpuset.cpus
[root@mordor:~]# echo 1 > /cgroup/cpuset/profs/cpuset.mems
[root@mordor:~]# echo $PIDS_pr > /cgroup/cpuset/profs/tasks
```

Slurm - Configuration avancée

- **Confinement des processus**

- Le cgroup « cpuset » par exemple permet

- de créer des groupes de processus associés aux jobs et jobsteps et d'associer à ces groupes les cores/cpus alloués

exemple : `srun -n 2 -p sandy sleep 1000`

47142 slurmstepd: [216978.0]

47159 47142 0 80 ... /usr/sbin/sleep 1000

47160 47142 0 80 ... /usr/sbin/sleep 1000

→ /sys/fs/cgroup/cpuset/slurm_inti1411/uid_3141/job_216978/step_0/tasks

47142 47159 47160

→/sys/fs/cgroup/cpuset/slurm_inti1411/uid_3141/job_216978/step_0/cpuset.
cpus

2-3

- **Idem pour la mémoire (« memcg »), les GPUs (« devices »), ...**

Slurm - Configuration avancée

- **Binding des processus**

- Linux/glibc fournit des primitives permettant de limiter l'exécution de processus sur certains cpus du système uniquement (cf « man set_schedaffinity »)

```
/proc/47160/status|grep Cpus_allowed_list
```

```
3
```

```
/proc/47159/status|grep Cpus_allowed_list
```

```
2
```

- Cette logique est utilisée dans task/cgroup pour répartir les cores alloués entre les processus et garantir leur immobilité pendant l'exécution
 - Améliorant les effets de cache

Slurm - Configuration avancée

- **Confinement et binding des processus**

- Exemple de cgroup.conf

TaskPlugin = task/cgroup,task/affinity

CgroupMountpoint=/dev/cgroup

CgroupAutomount=yes

CgroupReleaseAgentDir="/etc/slurm/cgroup"

ConstrainCores=yes


TaskAffinity=yes

The background of the slide is composed of several large, overlapping triangles in various colors: red, orange, yellow, teal, blue, and purple. These triangles are arranged in a way that creates a dynamic, abstract geometric pattern. The central area where the text is located is a light gray, providing a clear contrast for the title.

Sécurité dans Slurm

Sécurité dans slurm

Sécuriser les requêtes entre commandes des utilisateurs/démons et entre démons/démons



Slurm - Sécurité

- Principaux objectifs de sécurité
 - Garantir un fonctionnement sécurisé en mode multi-utilisateurs

squeue

JOBID	PARTITION	NAME	USER	ST	TIME	NODES
NODELIST(REASON)						
21	vm	sleep hautreux	R	2:14	2	vm[1,3]
19	vm	sleep regine.g	R	4:26	1	vm3

[root@vm3 ~]# ps -elf (extrait)

F	S	UID	PID	PPID	C	PRI	STIME	TTY	CMD
1	S	root	846	1	0	80	08:29	?	/usr/sbin/slurmd
4	S	root	1375	1	0	80	08:30	?	slurmstepd: [19.0]
4	S	root	1461	1	0	80	08:33	?	slurmstepd: [21.0]
4	S	hautreux	1466	1461	0	80	08:33	?	/bin/sleep 2000
4	S	regine.gaudin	1380	1375	0	80	08:30	?	/bin/sleep/1000

Slurm - Sécurité

- **Principaux objectifs de sécurité**
 - Garantir un fonctionnement sécurisé en mode multi-utilisateurs
 - Notion de « multi-tenant » (multi-tenancy)
 - Plusieurs utilisateurs utilisent le même service
 - Exécution de programmes à l'identité des utilisateurs en faisant la demande
 - Nécessité de restreindre les droits à ceux de l'utilisateur en question le temps des jobs

Slurm - Sécurité

- **Principaux objectifs de sécurité**
 - Garantir la validité des identités des utilisateurs
 - Authentification des utilisateurs
 - Garantir l'authenticité des autorisations d'accès aux ressources accordées par le contrôleur
 - Pour garantir un fonctionnement sécurisé et performant en environnement distribué

Slurm - Sécurité

- « **Security Plugins** » : **Auth plugin**

Méthode d' Authentification

- Plugin permettant la fourniture d'une méthode d'authentification des messages basée sur un concept d'informations de validation « auth_info »
- Chaque message contient une section « auth_info » générée par l'émetteur et validée par le récepteur qui en extrait les uid/gid de l'émetteur

Slurm - Sécurité

- **Auth Plugin - Authentification**

- Trois choix possibles

- None : confiance totale envers les utilisateurs du système.
 - Les uid/gid fournis par l'utilisateur sont considérés comme fiables !
 - Implémentation **Munge** : utilisation d'un système annexe nommé Munge (recommandé)
 - AuthType = auth/munge
 - Authentification interne de Slurm (≥ 23.11)
 - AuthType = auth/slurm

Slurm - Sécurité

- **Munge Recommandé**

- MUNGE service d'authentification pour créer et valider les informations d'identification des utilisateurs.
- MUNGE est le système recommandé par les développeurs de Slurm pour le plugin d'authentification.
- MUNGE (MUNGE Uid aNd Gid Emporium) est un produit développé par le LLNL
 - <https://dun.github.io/munge/>
- MUNGE est disponible nativement sur de nombreuses distributions Linux

Slurm - Sécurité

- **MUNGE**

- Repose sur le partage d'un secret (/etc/munge/munge.key) partagé par l'ensemble des nœuds intégrés dans un même espace de confiance (REALM)
- Repose sur la possibilité d'obtenir de façon fiable l'UID et le GID d'origine d'une connexion de type Socket BSD sur les systèmes UNIX.
- Fourni une API C et des commandes pour une utilisation scriptée

Slurm - Sécurité

- **MUNGE**


- `munge exe/munge_encode()` permet de générer un « munge credential » chiffré intégrant :
 - L'UID et le GID de l'utilisateur à l'initiative de la requête
 - Un contenu avec des infos à transmettre de façon sécurisé
 - La date d'émission et le TTL (time-to-live)
 - Une restriction optionnelle sur l'UID/GID autorisé à déchiffrer le « credential »

Slurm - Sécurité

- **MUNGE**

- `unmunge exe/munge_decode()` permet de déchiffrer un « munge credential »
 - À condition que l'UID/GID à l'initiative soit autorisé à effectuer l'opération
 - Afin de vérifier qu'il n'est pas expiré
 - Afin de vérifier qu'il n'a pas été « rejoué »
 - Le même credential a déjà été traité préalablement
 - Afin d'obtenir l'UID/GID de l'émetteur
 - Afin d'obtenir le contenu déchiffré

Slurm - Sécurité



Slurm - Sécurité

- **Auth Plugin - MUNGE**

- Chaque requête Slurm commande/démon ou démon/démon
 - génère des « credentials » associés à son UID/GID et les ajoute à ses messages
 - valide les « credentials » des messages qu'il reçoit et valide que les UID/GID associés sont licites pour le service requis

Slurm - Sécurité

- **Auth Plugin - interne**
 - Aussi basé sur une clé secrète partagée
 - Matching UID/GID
 - Intégration avec Json Web Tokens
 - Échange sécurisé (chiffré) de jetons

Il n'y a plus qu'à mettre cela en place par vous même...

Ce sera l'objet du TP 2

`/home/shared/lise.jolicoeur/tp-slurm2`